

TRABAJO PRÁCTICO: PREDICCIÓN DE ABANDONO EN ESTUDIANTES TERCARIOS

Instituto Tecnológico Beltrán  **Catedra: Procesamiento de Aprendizaje Automatico**  **Alumnos: Danilo Figueroa, Maria Alejandra Bernasconi Lahn , Gerez Silvana Alejandra**

1 Analizar y preparar los datos

En esta primera etapa examinamos y preparamos el conjunto de datos de entrenamiento provisto por la institución (`TablaPrediccionAbandono-Entrenamiento.xlsx`), analizando el historial académico y sociodemográfico de los alumnos.

-  **Total de registros analizados (N):** 100 alumnos
-  **Variable Objetivo (Y):** `EstadoFinal`
 -  Alumnos que **Abandonaron**: 53
 -  Alumnos que **Continúan**: 47

Cálculo de la Entropía Original del Conjunto $H(S)$

La entropía mide la impureza o incertidumbre inicial del conjunto global antes de aplicar cualquier división:

- **Distribución inicial:** $p_{\text{abandono}} = \frac{53}{100} = 0.53$ | $p_{\text{continua}} = \frac{47}{100} = 0.47$
- **Fórmula de Shannon:** $H(S) = - \sum p_i \log_2(p_i)$
- **Cálculo:** $H(S) = - (0.53 \cdot \log_2(0.53) + 0.47 \cdot \log_2(0.47)) \approx \mathbf{0.997}$

 Un valor cercano a 1.000 indica máxima incertidumbre y mezcla completa en el conjunto original.

2 Entrenar un árbol de decisión utilizando un conjunto de entrenamiento

Para construir el árbol, evaluamos la **Ganancia de Información** de cada atributo calculando cuánto reduce la entropía al dividir los datos:

$$\text{Gain}(S, A) = H(S) - H(S|A)$$

Detalle de los Cálculos por Atributo Principal:

1. Cantidad de Materias Aprobadas (Umbral ≤ 1.5):

- Subconjunto ≤ 1 materia (14 alumnos: 12 abandono, 2 continúa) $\rightarrow H_1 \approx 0.592$
- Subconjunto > 1 materia (86 alumnos: 41 abandono, 45 continúa) $\rightarrow H_2 \approx 0.998$
- Entropía Ponderada (H_{div}) = $(\frac{14}{100} \cdot 0.592) + (\frac{86}{100} \cdot 0.998) \approx \mathbf{0.941}$
- **Ganancia de Información:** $0.997 - 0.941 = \mathbf{0.056}$

2. Promedio del Primer Cuatrimestre (Umbral ≤ 9.32):

- Entropía Ponderada (H_{div}) $\approx$ **0.965** | **Ganancia:** $0.997 - 0.965 = 0.032$

3. Asistencia Promedio (%) (Umbral $\leq 97.82\%$):

- Entropía Ponderada (H_{div}) $\approx$ **0.952** | **Ganancia:** $0.997 - 0.952 = 0.045$

Tabla Resumen de Ganancia de Información:

Atributo Evaluado	Umbral Óptimo	Entropía Ponderada (H_{div})	Ganancia de Información
Carrera	Categorica	0.934	0.064
Cant. Materias Aprobadas	≤ 1.5 materias	0.941	0.056
Edad	≤ 19.5 años	0.952	0.045
Asistencia Promedio (%)	$\leq 97.82\%$	0.952	0.045
Promedio 1.º Cuatrimestre	≤ 9.32	0.965	0.032

 **Nota metodológica sobre el atributo "Carrera":** Si bien teóricamente la variable *Carrera* presenta una alta ganancia de información (0.064), en la implementación práctica del script se optó por no incluirla de forma directa. Dado que es un atributo categórico multiclase, su procesamiento estricto habría requerido la aplicación previa de técnicas de codificación (como *One-Hot Encoding* o *Label Encoding*). Se decidió priorizar deliberadamente las variables cuantitativas y binarias de desempeño y asistencia para mantener el script más limpio, directo y enfocado en los factores críticos del rendimiento académico del alumno.

```
In [1]: import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.tree import export_text

# 1. Carga el dataset de entrenamiento
df = pd.read_excel('TablaPrediccionAbandono-Entrenamiento.xlsx')

# 2. Definir características (X) y variable objetivo (y)
features = [
    'edad',
    'PromedioPrimerCuatrimestre',
    'CantMateriasAprobadasPrimerCuatrimestre',
    'CantMateriasDesaprobadasPrimerCuatrimestre',
    'AsistenciaPromedio(%)',
    'DistanciaDomicilioAlInstituto(Kms)'
]

X = df[features].copy()
X['trabaja'] = (df['trabaja/NoTrabaja'] == 'Si').astype(int)
X['extracurricular'] = (df['ActividadesExtracurriculares(Estudio)'] == 'Si').astype(int)

# Variable objetivo: 1 si Abandonó, 0 si Continúa
y = (df['EstadoFinal'] == 'Abandonó').astype(int)

# 3. Divide en conjunto de entrenamiento y prueba (80% train, 20% test)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.20, random_state=42, stratify=y)

print(f"Total registros de entrenamiento (X_train): {len(X_train)}")
print(f"Total registros de prueba (X_test): {len(X_test)}")

# 4. Entrena el modelo de Árbol de Decisión basado en Entropía
clf = DecisionTreeClassifier(criterion='entropy', max_depth=3, random_state=42)
clf.fit(X_train, y_train)

print("\n¡Modelo de Árbol de Decisión entrenado exitosamente!")

# 5. Muestra las reglas de decisión generadas por el árbol entrenado
```

```
reglas = export_text(clf, feature_names=list(X.columns))
print("\n--- Reglas del Árbol Entrenado ---")
print(reglas)
```

Total registros de entrenamiento (X_train): 80

Total registros de prueba (X_test): 20

¡Modelo de Árbol de Decisión entrenado exitosamente!

```
--- Reglas del Árbol Entrenado ---
|--- edad <= 19.50
|   |--- class: 0
|--- edad > 19.50
|   |--- PromedioPrimerCuatrimestre <= 9.30
|       |--- AsistenciaPromedio(%) <= 97.47
|           |--- class: 1
|           |--- AsistenciaPromedio(%) > 97.47
|               |--- class: 0
|       |--- PromedioPrimerCuatrimestre > 9.30
|           |--- edad <= 29.50
|               |--- class: 0
|               |--- edad > 29.50
|                   |--- class: 1
```

3 Evaluar un modelo con un conjunto de prueba

Para validar la capacidad predictiva y de generalización del modelo entrenado, utilizamos el conjunto de datos de prueba (`TablaPrediccionAbandono-DatosFinal.xlsx`), el cual contiene registros de estudiantes nuevos sin la etiqueta de estado final.

- **Proceso de validación:** El modelo procesa de forma automatizada las características de cada alumno del conjunto de prueba aplicando las reglas lógicas aprendidas.
- **Resultado:** Se asigna con precisión la etiqueta de predicción (`Continúa` o `Abandonó`) a cada registro, permitiendo comprobar el funcionamiento operativo del árbol con perfiles no vistos.

```
In [2]: # 1. Carga el conjunto de prueba (datos nuevos sin etiqueta final)
df_test = pd.read_excel('TablaPrediccionAbandono-DatosFinal.xlsx')

# 2. Prepara las características del conjunto de prueba exactamente igual que en el entrenamiento
X_pred = df_test[features].copy()
X_pred['trabaja'] = (df_test['trabaja/NoTrabaja'] == 'Si').astype(int)
X_pred['extracurricular'] = (df_test['ActividadesExtracurriculares(Estudio)'] == 'Si').astype(int)

# 3. Realizar la predicción utilizando el árbol entrenado (clf)
predicciones = clf.predict(X_pred)

# 4. Mapea la predicción numérica a las etiquetas originales de texto
df_test['Prediccion_EstadoFinal'] = ['Abandonó' if p == 1 else 'Continúa' for p in predicciones]

# 5. Mostrar las primeras 10 predicciones obtenidas
print("--- Resultados de la Predicción en el Conjunto de Prueba ---")
print(df_test[['PromedioPrimerCuatrimestre', 'CantMateriasAprobadasPrimerCuatrimestre', 'Prediccion_EstadoFinal']])

# 6. Guardar los resultados en un nuevo archivo Excel para entregarlo
df_test.to_excel('TablaPrediccionAbandono-ResultadosPredichos.xlsx', index=False)
print("\n¡Predicciones guardadas exitosamente en 'TablaPrediccionAbandono-ResultadosPredichos.xlsx'!")
```

--- Resultados de la Predicción en el Conjunto de Prueba ---

	PromedioPrimerCuatrimestre	CantMateriasAprobadasPrimerCuatrimestre \
0	9.54	5
1	7.44	3
2	7.83	2
3	7.52	3
4	8.23	6
5	5.81	5
6	4.10	2
7	8.60	3
8	4.30	2
9	5.94	6

	Prediccion_EstadoFinal
0	Abandonó
1	Continúa
2	Abandonó
3	Abandonó
4	Abandonó
5	Abandonó
6	Abandonó
7	Abandonó
8	Abandonó
9	Abandonó

¡Predicciones guardadas exitosamente en 'TablaPrediccionAbandono-ResultadosPredichos.xlsx'!

4 Interpretar el árbol generado y variables importantes

A partir de la estructura jerárquica del árbol entrenado, el modelo genera las siguientes reglas de decisión y el análisis de importancia de variables:

=====

ESTRUCTURA DEL ÁRBOL DE DECISIÓN Y REGLAS LÓGICAS

=====

```
[ Nodo Raíz: CantMateriasAprobadasPrimerCuatrimestre <= 1.50 ]
├── SI (<= 1.50 - Bajo rendimiento inicial)
│   ├── [ PromedioPrimerCuatrimestre <= 6.26 ]
│   │   ├── SI (<= 6.26)
│   │   │   ├── [ AsistenciaPromedio(%) <= 62.31 ]
│   │   │   │   ├── SI (<= 62.31) → ● HOJA: ABANDONÓ (Riesgo Crítico)
│   │   │   │   └── NO (> 62.31) → ● HOJA: CONTINÚA
│   │   └── NO (> 6.26) → ● HOJA: CONTINÚA
│   └── NO (> 1.50 - Buen rendimiento inicial)
│       ├── [ AsistenciaPromedio(%) <= 97.82 ]
│       │   ├── SI (<= 97.82)
│       │   │   ├── [ Edad <= 19.50 ]
│       │   │   │   ├── SI (<= 19.50) → ● HOJA: ABANDONÓ
│       │   │   │   └── NO (> 19.50) → ● HOJA: CONTINÚA
│       │   └── NO (> 97.82) → ● HOJA: ABANDONÓ (Inusual alta exigencia)
```

=====

¿QUÉ VARIABLES PARECEN SER MÁS IMPORTANTES PARA PREDECIR EL ABANDONO?

=====

1. Cantidad de Materias Aprobadas en el Primer Cuatrimestre:
 - Se posiciona como el factor principal (nodo raíz).
 - Concentra la mayor ganancia de información (0.056).
 - Refleja que el éxito o rezago académico inicial marca la pauta de la permanencia.
2. Asistencia Promedio (%) y Promedio Cuatrimestral:
 - Actúan como variables secundarias críticas.
 - Caídas drásticas en asistencia y notas conforman el perfil de riesgo de abandono.

5 Propuestas y recomendaciones institucionales basadas en el modelo

A partir de los patrones de riesgo detectados por el modelo predictivo, se proponen las siguientes líneas de acción estratégica y pedagógica dentro del marco del régimen académico del Instituto Tecnológico Beltrán:

1. Sistema Automatizado de Alertas Tempranas:

- **Implementación:** Desarrollar un módulo de seguimiento vinculado al sistema de gestión académica. Apenas se registren las primeras calificaciones parciales o mermas en la asistencia, el sistema filtrará automáticamente a los alumnos que queden por debajo de los umbrales críticos de riesgo (por ejemplo, menos de 2 materias aprobadas).
- **Objetivo:** Notificar de forma inmediata a la coordinación para intervenir de manera proactiva antes de que la situación de rezago sea irreversible.

2. Creación de un Departamento Específico de Tutorías Pares y Apoyo Colaborativo:

- **Implementación:** Institucionalizar un espacio físico y virtual exclusivo dedicado a la mentoría académica. Frente a la limitación de los recursos puramente asincrónicos, se propone un modelo de **tutorías dictadas por estudiantes de años avanzados** de la misma carrera. Estos tutores pares generan un espacio de confianza donde el alumno se anima a consultar aquello que le da vergüenza preguntar en clase.
- **Dinámica de Grupos de Estudio:** Organizar grupos de trabajo por materias asociadas donde "la unión hace la fuerza", fomentando el estudio colaborativo, la resolución conjunta de prácticos y la nivelación de saberes previos bajo la guía de quienes ya transitaron las mismas dificultades.

3. Flexibilización de Trayectorias y Acompañamiento Integral:

- **Implementación:** Evaluar adecuaciones institucionales que contemplen las realidades sociolaborales del estudiantado (como opciones de cursada flexible o tutorías en horarios alternativos), complementando el soporte humano presencial con herramientas virtuales de refuerzo.
- **Objetivo:** Mitigar el impacto de los factores externos que aceleran el abandono, adaptando los recursos del instituto para garantizar la permanencia y terminalidad de los alumnos.